

Modelamiento de la Ley de Mersenne en una Guitarra Acústica mediante Regresión Simbólica

*Construcción de un dataset experimental bivariado
y redescubrimiento de la fórmula $f_0 = \frac{1}{2L}\sqrt{\frac{T}{\mu}}$*

Juan Diego Martinez - Kevin Cruz

Modelamiento en Física Computacional

Abril, 2026

Resumen

Se presenta el proceso completo de modelamiento de la **Ley de Mersenne** para cuerdas vibrantes utilizando datos obtenidos experimentalmente en una guitarra acústica D'Addario EJ16. Se extrajeron frecuencias fundamentales f_0 mediante la Transformada Rápida de Fourier (FFT) en 120 grabaciones de audio (6 cuerdas $\times$ 20 trastes). A continuación, cada variable de la ley de Mersenne fue estudiada de forma *estrictamente bivariada*: $f_0(L)$ con ajuste potencial log-log, $f_0(\mu)$ aprovechando la variedad de cuerdas del juego, y $f_0(T)$ mediante medición experimental de tensión con un diagrama de cuerpo libre. Finalmente, se aplicó regresión simbólica (log-lineal multivariable más búsqueda genética con `gplearn`) sobre el *dataset* combinado. Los exponentes recuperados $b_L = -0.999$, $b_\mu = -0.473$, $b_T = +0.441$ convergen hacia los valores teóricos de Mersenne $(-1, -\frac{1}{2}, +\frac{1}{2})$ con un coeficiente de determinación $R^2 = 0.992$ en el modelo conjunto.

Índice

1. Introducción	3
2. Marco Teórico	3
2.1. La ecuación de onda en una cuerda	3
2.2. Leyes de potencia implícitas	4
2.3. Linealización log-log	4
3. Configuración Experimental	4
3.1. Instrumento y cuerdas	4
3.2. Longitudes vibrantes	5
3.3. Sistema de adquisición de audio	5
4. Paso 1 — Extracción de Frecuencias Fundamentales por FFT	5
4.1. Metodología	5
4.2. Resultados	7
5. Paso 2 — Relación $f_0 \propto L^{-1}$	7
5.1. Principio teórico	7
5.2. Variables utilizadas	7
5.3. Ajuste potencial	7
5.4. Verificación: $f_0 \cdot L = \text{cte}$	8
5.5. Figuras	9
6. Paso 3 — Relación $f_0 \propto \mu^{-1/2}$	9
6.1. Principio teórico	10
6.2. Variables utilizadas	10
6.3. Datos	10
6.4. Ajuste potencial	10
6.5. Figuras	11
7. Paso 4 — Relación $f_0 \propto T^{+1/2}$	12
7.1. Diagrama de cuerpo libre — Medición de tensión	12
7.2. Variables utilizadas	12
7.3. Datos experimentales	13
7.4. Ajuste potencial y error sistemático	13
7.5. Figuras	14

8. Regresión Simbólica — Síntesis de la Ley de Mersenne	14
8.1. Estrategia general	14
8.2. Dataset combinado	15
8.3. Modelo 1: (f_0, L, μ)	15
8.4. Modelo 2: (f_0, T)	15
8.5. Modelo 3: Regresión conjunta (f_0, L, μ, T)	16
8.6. Búsqueda genética con gplearn	16
8.7. Síntesis de exponentes y convergencia a Mersenne	17
9. Discusión	18
9.1. Convergencia de los exponentes	18
9.2. Inarmonicidad y desviación de b_L	19
9.3. Validez del enfoque bivariado	19
9.4. gplearn vs. regresión log-lineal	19
10. Conclusiones	19
Referencias	20
A. Estructura de archivos del proyecto	21
B. Fragmentos de código clave	22
B.1. Extracción de f_0 por FFT (<code>analisis_guitarra.py</code>)	22
B.2. Ajuste potencial log-log (<code>analisis_paso2_fL.py</code>)	23
B.3. Regresión simbólica log-lineal (<code>regresion_simbolica.py</code>)	23
B.4. Medición de tensión — DCL (<code>analisis_paso4_T.py</code>)	23

§1. Introducción

La **regresión simbólica** es una técnica de aprendizaje automático que busca la forma funcional de una ley física directamente a partir de datos, sin hipótesis previas sobre la expresión matemática. A diferencia de la regresión paramétrica clásica, el algoritmo no ajusta parámetros de un modelo ya fijado, sino que explora un espacio de expresiones generadas por operaciones elementales (multiplicación, división, raíz, potencia, etc.) mediante estrategias evolutivas.

En este trabajo se aplica esta metodología para *redescubrir* la **Ley de Mersenne**:

$$f_0 = \frac{1}{2L} \sqrt{\frac{T}{\mu}} \quad (1)$$

donde f_0 es la frecuencia fundamental de la cuerda, L la longitud vibrante, T la tensión y μ la densidad lineal de masa.

La estrategia se divide en cuatro pasos:

1. **Extracción de f_0** : análisis espectral FFT de grabaciones de audio.
2. **Análisis $f_0(L)$** : variación sistemática de la longitud vibrante mediante trastes.
3. **Análisis $f_0(\mu)$** : seis cuerdas con densidades de masa distintas.
4. **Análisis $f_0(T)$** : deformación controlada de la cuerda 5 con masas conocidas.

Cada paso es *estrictamente bivariado*: en el análisis de f_0 vs. X no se utiliza ninguna de las otras variables (Y , Z) de la ley de Mersenne, garantizando independencia experimental. El *dataset* combinado se construye únicamente al final para la regresión simbólica.

§2. Marco Teórico

2.1. La ecuación de onda en una cuerda

El movimiento transversal de una cuerda perfectamente flexible, uniforme y sometida a tensión T con densidad lineal de masa μ obedece la ecuación de onda:

$$\frac{\partial^2 y}{\partial t^2} = \frac{T}{\mu} \frac{\partial^2 y}{\partial x^2}, \quad (2)$$

cuya velocidad de propagación es $v = \sqrt{T/\mu}$.

Para una cuerda de longitud L fija en ambos extremos, las condiciones de contorno $y(0, t) = y(L, t) = 0$ imponen longitudes de onda cuantizadas:

$$\lambda_n = \frac{2L}{n}, \quad n = 1, 2, 3, \dots \quad (3)$$

Las frecuencias correspondientes son $f_n = v/\lambda_n$. Para el modo fundamental ($n = 1$):

$$f_0 = \frac{v}{2L} = \frac{1}{2L} \sqrt{\frac{T}{\mu}}. \quad (4)$$

2.2. Leyes de potencia implícitas

La ley de Mersenne puede reescribirse como el producto de tres leyes de potencia independientes:

$$f_0 \propto L^{-1} \quad (5)$$

$$f_0 \propto \mu^{-1/2} \quad (6)$$

$$f_0 \propto T^{+1/2} \quad (7)$$

Esto permite estudiar cada relación de forma bivariada, manteniendo las otras dos variables constantes o eliminándolas por diseño experimental. Los exponentes teóricos constituyen el objetivo de la regresión simbólica:

$$f_0 = C \cdot L^{b_L} \cdot \mu^{b_\mu} \cdot T^{b_T}, \quad b_L = -1, \quad b_\mu = -\frac{1}{2}, \quad b_T = +\frac{1}{2}. \quad (8)$$

2.3. Linealización log-log

Tomando logaritmo en base 10 a ambos miembros:

$$\log f_0 = \log C + b_L \log L + b_\mu \log \mu + b_T \log T. \quad (9)$$

Esto convierte la búsqueda de exponentes en una *regresión lineal multivariable en espacio logarítmico*, que es la base de los tres modelos de regresión simbólica empleados.

§3. Configuración Experimental

3.1. Instrumento y cuerdas

Se utilizó una guitarra acústica con escala de 65.2 cm (longitud vibrante al aire, traste 0). El juego de cuerdas empleado fue **D'Addario EJ16 Light Gauge** (bronce fosforado), cuyas propiedades se detallan en la Tabla 1.

Cuadro 1: Propiedades del juego D’Addario EJ16 Light Gauge. μ es la densidad lineal de masa especificada por el fabricante; T_{cat} es la tensión de catálogo a afinación estándar en escala de 25.5 [3]. Ambas son mediciones experimentales del fabricante, independientes de la ley de Mersenne.

Cuerda	Nota	Calibre	Material	μ (kg m ⁻¹)	T_{cat} (N)
1	Mi ₄ (E4)	.012” plain	Acero	3.90×10^{-4}	71.65
2	Si ₃ (B3)	.016” plain	Acero	7.05×10^{-4}	68.54
3	Sol ₃ (G3)	.024w wound	Bronce fosf.	1.59×10^{-3}	73.87
4	Re ₃ (D3)	.032w wound	Bronce fosf.	2.84×10^{-3}	81.42
5	La ₂ (A2)	.042w wound	Bronce fosf.	4.98×10^{-3}	90.30
6	Mi ₂ (E2)	.053w wound	Bronce fosf.	7.97×10^{-3}	82.31

3.2. Longitudes vibrantes

Las longitudes vibrantes L (distancia del puente al traste presionado) se midieron con calibrador para los 20 trastes (0 al 19). La Tabla 2 recoge los valores.

Cuadro 2: Longitudes vibrantes L medidas experimentalmente por traste.

Traste	L (cm)	Traste	L (cm)	Traste	L (cm)	Traste	L (cm)
0	65.2	5	50.2	10	37.4	15	28.1
1	63.2	6	46.7	11	35.4	16	26.4
2	59.7	7	44.7	12	33.4	17	24.9
3	56.3	8	42.2	13	31.4	18	23.5
4	53.2	9	39.7	14	29.7	19	22.4

3.3. Sistema de adquisición de audio

Las grabaciones de audio se realizaron punteando cada cuerda en cada traste (120 combinaciones en total). Los archivos de audio se procesaron con la función `analisis_guitarra.py` descrita en la Sección 4.


§4. Paso 1 — Extracción de Frecuencias Fundamentales por FFT

4.1. Metodología


Para cada uno de los 120 archivos de audio se ejecuta el siguiente procedimiento en `analisis_guitarra.py`:

1. Lectura del archivo WAV y conversión a señal monocanal normalizada.
2. Ventaneo de Hann para reducir *spectral leakage*.
3. Transformada Rápida de Fourier (`numpy.fft.rfft`) sobre toda la señal.
4. Cálculo del espectro de potencia $|X(f)|^2$.
5. Detección del pico de mayor amplitud en el rango de frecuencias esperado para cada cuerda (ventana adaptativa de $\pm 30\%$ en torno a la frecuencia nominal).
6. Refinamiento sub-bin mediante interpolación parabólica sobre los tres puntos del pico.
7. Exportación a `frecuencias_fundamentales.csv`.

La Figura 1 muestra espectros representativos para las seis cuerdas al aire (traste 0). Los picos fundamentales se aprecian con claridad y la resolución espectral es suficiente para discriminar entre semitonos a frecuencias bajas.



(a) C1 — Mi₄ (E₄), traste 0



(b) C6 — Mi₂ (E₂), traste 0

Figura 1: Espectros de potencia FFT: cuerda más aguda (izq.) y más grave (der.) al aire. Los armónicos superiores se aprecian como picos secundarios a múltiplos enteros de f_0 .




Figura 2: Mapa global de frecuencias fundamentales f_0 (Hz) para las 120 combinaciones (cuerda, traste). El eje horizontal indexa el traste y el color diferencia la cuerda.




Figura 3: Superposición de espectros por traste para una misma cuerda. A medida que el traste aumenta (longitud vibrante decrece) el pico fundamental se desplaza hacia frecuencias más altas.

4.2. Resultados

El archivo `frecuencias_fundamentales.csv` contiene 120 filas con tres columnas: `cuerda`, `traste`, `f0_Hz`. Las frecuencias fundamentales oscilan entre 82 Hz (C6, traste 0) y 999 Hz (C1, traste 19).

§5. Paso 2 — Relación $f_0 \propto L^{-1}$

5.1. Principio teórico

Con tensión T y densidad μ fijas para una cuerda dada, la ley de Mersenne (1) predice:

$$f_0 \cdot L = \frac{1}{2} \sqrt{\frac{T}{\mu}} = \text{constante.} \quad (10)$$

Esto equivale a un ajuste potencial $f_0 = a \cdot L^b$ con exponente teórico $b = -1$.

5.2. Variables utilizadas

- **Entrada:** f_0 (Hz) de `frecuencias_fundamentales.csv` y L (cm) de `Distancias.txt`.
- **No se emplea:** μ ni T en ninguna parte del análisis bivariado.

5.3. Ajuste potencial

Para cada cuerda k se ajusta en escala log-log:

$$\log_{10} f_0 = b_k \cdot \log_{10} L + \log_{10} a_k, \quad (11)$$

con detección de *outliers* para puntos en que $|f_0^{\text{med}} - f_0^{\text{pred}}|/f_0^{\text{pred}} > 0.15$.

Los resultados por cuerda se muestran en la Tabla 3.

Cuadro 3: Parámetros del ajuste potencial $f_0 = a \cdot L^b$ por cuerda. R^2 calculado en espacio logarítmico.

C.	Nota	a (Hz·m)	b	R^2	$\Delta b = b - (-1)$
1	Mi ₄ (E4)	212.86	-1.0326	0.99779	-0.0326
2	Si ₃ (B3)	161.94	-1.0274	0.99871	-0.0274
3	Sol ₃ (G3)	128.24	-1.0265	0.99851	-0.0265
4	Re ₃ (D3)	96.51	-1.0162	0.99961	-0.0162
5	La ₂ (A2)	72.59	-1.0106	0.99938	-0.0106
6	Mi ₂ (E2)	54.32	-1.0147	0.99942	-0.0147
Teórico		—	-1.0000	—	—

Resultado Paso 2

El exponente b_L se recupera con alta precisión en todas las cuerdas, con desviaciones $|\Delta b| < 0.034$. La desviación sistemática negativa ($b < -1$) corresponde a la **inarmonicidad** intrínseca de cuerdas con rigidez finita: a longitudes vibrantes cortas los modos son ligeramente más rígidos de lo que predice el modelo de cuerda ideal. El coeficiente $R^2 > 0.997$ en todos los casos confirma la validez de la ley de potencia.


5.4. Verificación: $f_0 \cdot L = \text{cte}$

La Tabla 4 reporta el producto $f_0 \cdot L$ promediado por cuerda, que debe ser constante para cada cuerda (ec. 10). El valor $c_k = 2f_0L$ es la velocidad de onda transversal en la cuerda.


Cuadro 4: Velocidad de onda transversal $c_k = 2f_0L$ por cuerda, promediada sobre los 20 trastes.

C.	Nota	$\overline{f_0L}$ (Hz·m)	$c_k = 2\overline{f_0L}$ (m/s)
1	Mi ₄ (E4)	219.63	439.26
2	Si ₃ (B3)	166.25	332.50
3	Sol ₃ (G3)	131.51	263.02
4	Re ₃ (D3)	97.99	195.98
5	La ₂ (A2)	73.33	146.66
6	Mi ₂ (E2)	55.09	110.19

5.5. Figuras




(a) C1 — Mi₄ (E4): ajuste f_0 vs L (izq.) y linealización log-log (der.).



(b) C5 — La₂ (A2): ajuste (izq.) y linealización (der.).

Figura 4: Ajuste potencial $f_0 = a \cdot L^b$ por cuerda. La pendiente en escala log-log es el exponente $b \approx -1$.



(a) Colapso normalizado: $f_0/f_0^{(T0)}$ vs. L/L_0 . Si $f_0 \propto L^{-1}$ todos los puntos deben caer sobre $y = 1/x$.

(b) Producto $f_0 \cdot L$ por traste. La horizontalidad de cada curva confirma que la constante $\frac{1}{2}\sqrt{T/\mu}$ no cambia con el traste.

Figura 5: Verificaciones globales de la ley $f_0 \propto L^{-1}$.

§6. Paso 3 — Relación $f_0 \propto \mu^{-1/2}$

6.1. Principio teórico

Fijando $L = L_0 = 65.2$ cm (cuerda al aire) y manteniendo T constante por cuerda (afinación estándar), la ley de Mersenne predice:

$$f_0 \propto \mu^{-1/2}, \quad (12)$$

es decir, cuerdas más pesadas vibran más lento.

6.2. Variables utilizadas

- **Entrada:** f_0 (Hz) de `frecuencias_fundamentales.csv` y μ (kg/m) de la ficha técnica D’Addario EJ16.
- **No se emplea:** L ni T en ninguna parte del análisis.

6.3. Datos

La Tabla 5 muestra f_0 medida al aire para las seis cuerdas junto con los valores de μ .

Cuadro 5: Frecuencias fundamentales al aire ($L_0 = 65.2$ cm) y densidades lineales de masa por cuerda.

C.	Nota	f_0 (Hz)	μ (kg/m)	$f_0\sqrt{\mu}$ (Hz·kg ^{1/2} m ^{-1/2})
1	Mi ₄ (E4)	328	3.90×10^{-4}	6.48×10^{-3}
2	Si ₃ (B3)	247	7.05×10^{-4}	6.56×10^{-3}
3	Sol ₃ (G3)	196	1.59×10^{-3}	7.82×10^{-3}
4	Re ₃ (D3)	146	2.84×10^{-3}	7.78×10^{-3}
5	La ₂ (A2)	109	4.98×10^{-3}	7.69×10^{-3}
6	Mi ₂ (E2)	82	7.97×10^{-3}	7.32×10^{-3}

Si $f_0 \propto \mu^{-1/2}$ exactamente, el producto $f_0\sqrt{\mu}$ debería ser constante para todas las cuerdas. La ligera variación observada (6.48 a 7.82×10^{-3}) se debe a que la tensión T no es idéntica en todas las cuerdas: las cuerdas entorchadas (C3–C6) poseen T ligeramente mayor que las lisas (C1–C2).

6.4. Ajuste potencial

Con seis puntos de ajuste (traste 0, una por cuerda):

$$f_0 = 10.20 \cdot \mu^{-0.4454}, \quad R^2 = 0.987. \quad (13)$$

Promediando el exponente sobre los 20 trastes:

$$\bar{b}_\mu = -0.414 \pm 0.058. \quad (14)$$

Resultado Paso 3

El exponente $b_\mu = -0.445$ (traste 0) se desvía del teórico -0.5 en $|\Delta b_\mu| = 0.055$. Esta desviación es física: la tensión T varía entre cuerdas ($\approx 10\text{--}20\%$), lo que parcialmente compensa el efecto de μ sobre f_0 . La regresión simbólica conjunta que controla T (Sección 8) recuperará un valor más cercano a -0.5 .

6.5. Figuras





Figura 6: f_0 vs. μ para los 20 trastes. Cada curva corresponde a un traste (longitud fija) y cae sobre la relación potencial $\mu^{-1/2}$.



(a) Distribución del exponente b_μ por traste. La línea punteada marca el teórico -0.5 .

(b) Colapso normalizado: f_0/f_0^{ref} vs. μ/μ_{ref} sobre $y = 1/\sqrt{x}$ (línea punteada).

Figura 7: Análisis global de la ley $f_0 \propto \mu^{-1/2}$.

§7. Paso 4 — Relación $f_0 \propto T^{+1/2}$

7.1. Diagrama de cuerpo libre — Medición de tensión

Se estudió únicamente la **cuerda 5** (La₂, A₂). El procedimiento experimental consistió en colgar masas de valores conocidos ($m \in \{120, 150, 220\}$ g) sobre la cuerda a distintas posiciones, medir el ángulo de deflexión θ y calcular la tensión mediante el equilibrio de fuerzas (Figura 8):




Figura 8: Diagrama de cuerpo libre para la medición de tensión. Equilibrio vertical: $2T \sin \theta = mg$, de donde $T = mg/(2 \sin \theta)$.

La ecuación de equilibrio en la dirección transversal es:

$$2T \sin \theta = mg \quad \Rightarrow \quad \boxed{T = \frac{mg}{2 \sin \theta}} \quad (15)$$

Tras cada configuración se punteó la cuerda y se midió f_0 mediante FFT. En total se obtuvieron **15 pares** (T, f_0) .

7.2. Variables utilizadas

- **Entrada:** f_0 (Hz) y T (N) calculada de la ec. (15).
- **No se emplea:** L ni μ en ninguna parte del análisis.

7.3. Datos experimentales

Cuadro 6: Datos de tensión y frecuencia — cuerda 5 (La₂, A2). La columna $f_0/\sqrt{T}$ debería ser constante si $f_0 \propto \sqrt{T}$.

Punto	m (g)	θ (°)	T (N)	f_0 (Hz)	$f_0/\sqrt{T}$
1	220	1.1	56.211	107.82	14.38
2	220	1.5	41.223	93.33	14.54
3	220	1.7	36.375	82.67	13.71
4	220	2.2	28.110	77.25	14.57
5	220	2.6	23.788	69.07	14.16
6	220	2.8	22.090	62.78	13.36
7	220	3.2	19.331	56.02	12.74
8	220	3.5	17.676	49.67	11.82
9	220	4.0	15.470	45.74	11.63
10	220	4.7	13.170	42.73	11.77
11	150	0.9	46.841	108.05	15.79
12	150	1.2	35.132	88.11	14.87
13	150	1.4	30.114	78.53	14.31
14	150	1.8	23.424	69.00	14.26
15	150	1.9	22.191	61.69	13.10

7.4. Ajuste potencial y error sistemático

$$f_0 = 7.330 \cdot T^{0.6889}, \quad R^2 = 0.971. \quad (16)$$

Error sistemático — Método de deflexión

El exponente obtenido ($b_T = +0.689$) es mayor que el teórico ($b_T = +0.500$), con $\Delta b_T = +0.189$. La causa es un **error sistemático** en la medición de T : la ecuación $T = mg/(2 \sin \theta)$ asume que la masa se cuelga exactamente en el punto medio de la cuerda con ángulo simétrico, lo que en la práctica no se garantizó. A ángulos pequeños ($\theta < 2^\circ$) un error de $\pm 0.1^\circ$ genera errores de hasta $\pm 10\%$ en T . La tensión medida resulta sistemáticamente menor que la real (aprox. 60 % del valor de catálogo D’Addario para C5), lo que infla el exponente observado. La tendencia cualitativa (f_0 crece con T) es correcta.

7.5. Figuras




Figura 9: Izq.: f_0 vs. T con ajuste potencial (línea continua). Der.: linealización log-log; la pendiente es $b_T = +0.689$ (teórico $+0.500$).




Figura 10: Colapso normalizado f_0/f_0^{ref} vs. T/T_{ref} . La curva punteada es la predicción teórica $y = \sqrt{x}$. Los datos siguen cualitativamente la raíz cuadrada pero con exponente mayor por el error sistemático en la medición de T .

§8. Regresión Simbólica — Síntesis de la Ley de Mersenne

8.1. Estrategia general

Se implementan tres modelos de regresión simbólica complementarios en `regresion_simbolica.py`

Modelo 1 Regresión log-lineal en (f_0, L, μ) usando los 120 puntos del paso 2. Los valores de μ provienen de la ficha técnica D’Addario y son independientes de Mersenne.

Modelo 2 Regresión log-lineal en (f_0, T) usando los 15 puntos del paso 4.

Modelo 3 Regresión conjunta en (f_0, L, μ, T) combinando el paso 2 (con T de catálogo D’Addario, una constante por cuerda) y el paso 4 (con T medida). Total: 128 filas.

Adicionalmente se ejecuta **gplearn**, un buscador genético de expresiones simbólicas en Python, sobre el *dataset* (f_0, L, μ) sin imponer forma funcional.

8.2. Dataset combinado

El *dataset* `dataset_mersenne.csv` contiene 128 filas con columnas `f0_Hz`, `L_m`, `mu_kg_m`, `T_N` y `fuelle` (`paso2_Tcat` / `paso4_Tmed`). La columna `T_N` es el único campo que combina datos de dos fuentes distintas; los restantes son puramente experimentales.

8.3. Modelo 1: (f_0, L, μ)

$$\log_{10} f_0 = b_L \log_{10} L + b_\mu \log_{10} \mu + \log_{10} C_1 \quad (17)$$

Resultado:

$$f_0 = 6.897 \cdot L^{-1.019} \cdot \mu^{-0.442}, \quad R^2 = 0.991. \quad (18)$$




Figura 11: Gráfico de paridad para el Modelo 1. $\text{RMSE} \approx 5\%$ relativo en la escala de frecuencias.

8.4. Modelo 2: (f_0, T)

$$f_0 = 7.330 \cdot T^{+0.689}, \quad R^2 = 0.971. \quad (19)$$

La desviación $b_T = +0.689$ vs. $+0.500$ se atribuye al error sistemático discutido en la Sección 7.

8.5. Modelo 3: Regresión conjunta (f_0 , L , μ , T)

Al incluir la tensión de catálogo como referencia independiente para el paso 2, la regresión conjunta corrige parcialmente el error sistemático de b_T :

$$f_0 = 0.854 \cdot L^{-0.999} \cdot \mu^{-0.473} \cdot T^{+0.441}, \quad R^2 = 0.992. \quad (20)$$




Figura 12: Paridad del Modelo 3 sobre el dataset combinado de 128 puntos.

8.6. Búsqueda genética con gplearn

El algoritmo `SymbolicRegressor` de `gplearn` realiza una búsqueda evolutiva (población 5000, 30 generaciones) en el espacio de expresiones generadas con las operaciones: `{mul, div, sqrt, inv, add, sub, neg}`.

Sobre el dataset (f_0, L, μ) de 120 puntos, el algoritmo alcanza $R^2 = 0.999$ pero con una expresión no compacta de más de 200 caracteres. Esto ilustra una limitación conocida de los algoritmos genéticos: la tendencia al sobreajuste con expresiones algebraicas equivalentes pero ilegibles. La regresión log-lineal produce resultados más interpretables y físicamente significativos.




Figura 13: Resultado del `SymbolicRegressor` de `gplearn`. Izq.: paridad ($R^2 = 0.999$, $\text{RMSE} < 1\%$). Der.: residuos relativos — el sobreajuste genera residuos pequeños pero la fórmula no es interpretable.

8.7. Síntesis de exponentes y convergencia a Mersenne

La Figura 14 y la Tabla 7 comparan los exponentes hallados en todos los modelos con los valores de Mersenne.

Cuadro 7: Resumen de exponentes hallados por regresión simbólica frente a los valores teóricos de la ley de Mersenne.

Modelo	b_L	b_μ	b_T	R^2
Modelo 1 (L, μ)	-1.019	-0.442	—	0.991
Modelo 2 (T)	—	—	+0.689	0.971
Modelo 3 (L, μ, T)	-0.999	-0.473	+0.441	0.992
<code>gplearn</code> (L, μ)	(expresión no compacta)			0.999
Mersenne (teórico)	-1.000	-0.500	+0.500	—




Figura 14: Comparación de exponentes descubiertos vs. teóricos (línea punteada negra). Verde: $|\Delta b| < 0.08$; naranja: $|\Delta b| < 0.20$; rojo: $|\Delta b| \geq 0.20$.




Figura 15: Curvas f_0 vs. L predichas por el Modelo 1 y el Modelo 3 comparadas con los datos medidos, para las seis cuerdas. Ambos modelos reproducen los datos con alta fidelidad.

§9. Discusión

9.1. Convergencia de los exponentes

La Tabla 7 muestra que los tres exponentes de la ley de Mersenne son recuperados con distintos grados de precisión:

- $b_L \approx -1.0$: recuperación excelente ($|\Delta b| < 2\%$). La variación de L sobre 20 trastes con 6 cuerdas (120 puntos) proporciona la mayor riqueza estadística del experimento.
- $b_\mu \approx -0.47$: recuperación buena ($|\Delta b| < 6\%$ en el Modelo 3). La desviación residual refleja la variación de T entre cuerdas ($\approx 15\%$) que no puede controlarse sin una medición independiente de T para todas las cuerdas.
- $b_T \approx +0.44$: recuperación aceptable ($|\Delta b| < 12\%$ en el Modelo 3). El error sistemático del método de deflexión (medición de ángulo con incertidumbre $\pm 0.1^\circ$) es la limitación principal. En el Modelo 3, la presencia de los valores de catálogo T_{cat} actúa como ancla que corrige parcialmente el sesgo, bajando b_T de $+0.689$ (Modelo 2 aislado) a $+0.441$.

9.2. Inarmonicidad y desviación de b_L

La desviación sistemática $b_L < -1$ (all cuerdas) es consistente con la teoría de la inarmonicidad de cuerdas con rigidez finita [2]. La relación de dispersión para una cuerda con módulo de flexión B es:

$$f_n = n f_0 \sqrt{1 + B n^2}, \quad (21)$$

donde B depende del calibre y el material. Las cuerdas entorchadas (C3–C6) muestran menores desviaciones ($b \approx -1.01$) que las cuerdas lisas de acero (C1–C2, $b \approx -1.03$), en concordancia con la mayor rigidez relativa de las cuerdas de acero de pequeño calibre.

9.3. Validez del enfoque bivariado

La estrategia de análisis estrictamente bivariado garantiza que cada ley de potencia se mide sin contaminación cruzada de otras variables. Sin embargo, introduce la necesidad de combinar fuentes de datos heterogéneas (medición propia de T vs. catálogo) para la regresión conjunta. Esto es aceptable siempre que las fuentes sean independientes de la hipótesis que se quiere verificar.

9.4. gplearn vs. regresión log-lineal

El algoritmo genético de gplearn alcanza $R^2 = 0.999$ pero produce expresiones algebraicamente equivalentes a $1/(L\sqrt{\mu})$ enmascaradas en una cadena de más de 200 caracteres. El coeficiente de parsimonia (`parsimony_coefficient = 0.005`) no fue suficiente para simplificar la expresión. Esto pone de manifiesto que para problemas con estructura de ley de potencia, la regresión log-lineal es superior en *interpretabilidad* aunque gplearn supera ligeramente en ajuste numérico.

§10. Conclusiones

Ley de Mersenne — Resultado principal

A partir de 128 mediciones experimentales completamente independientes (120 espectros FFT de guitarra + 15 ensayos de tensión por deflexión), la regresión simbólica log-lineal recupera los tres exponentes de la ley de Mersenne con los resultados del Modelo 3:

$$f_0 = C \cdot L^{-0.999} \cdot \mu^{-0.473} \cdot T^{+0.441} \quad (R^2 = 0.992)$$

que converge hacia la forma exacta:

$$f_0 = \frac{1}{2L} \sqrt{\frac{T}{\mu}} \iff b_L = -1, \quad b_\mu = -\frac{1}{2}, \quad b_T = +\frac{1}{2}.$$

Las conclusiones específicas son:

1. La **ley** $f_0 \propto L^{-1}$ se verifica con $R^2 > 0.997$ en todas las cuerdas. La desviación $|\Delta b_L| < 3.5\%$ es física (inarmónica) y sistemáticamente mayor en cuerdas lisas de acero.
2. La **ley** $f_0 \propto \mu^{-1/2}$ se verifica con $b_\mu = -0.445$ (traste 0) y $\bar{b}_\mu = -0.414$ (promedio 20 trastes). La desviación residual se debe a la variación de T entre cuerdas que no pudo controlarse experimentalmente.
3. La **ley** $f_0 \propto T^{+1/2}$ se verifica cualitativamente. El error sistemático del método de deflexión ($b_T = +0.689$ aislado) se reduce a $+0.441$ en la regresión conjunta gracias al ancla de los valores de catálogo.
4. La **regresión simbólica log-lineal** es el método óptimo para este tipo de problemas: produce exponentes interpretables directamente relacionados con la física, mientras que la búsqueda genética (gplearn) sobreajusta con expresiones ilegibles.
5. El enfoque de **datasets bivariados independientes** es viable para la regresión simbólica multivariable, siempre que las fuentes de datos sean realmente independientes de la fórmula objetivo.

Referencias

Referencias

- [1] M. Mersenne, *Harmonie Universelle*, Cramoisy, París, 1636.
- [2] N. H. Fletcher y T. D. Rossing, *The Physics of Musical Instruments*, Springer, 2a ed., 1998, cap. 2.
- [3] D'Addario & Co., *String Tension Chart — EJ16 Phosphor Bronze Light Gauge*, https://www.daddario.com/globalassets/pdfs/accessories/tension_chart_13934.pdf, accedido abril 2026.
- [4] M. Cranmer, *Interpretable Machine Learning for Physics*, arXiv:2211.16487, 2022.

- [5] T. Stephens, *gplearn: Genetic Programming in Python*, <https://github.com/trevorstephens/gplearn>, 2024.
- [6] P. Virtanen et al., *SciPy 1.0: Fundamental algorithms for scientific computing in Python*, Nature Methods 17, 261–272 (2020).

§A. Estructura de archivos del proyecto

Listing 1: Árbol de archivos del proyecto.

```

1 Taller_Guitarra/
2     AUDIOS GUITARRA/                # 120 grabaciones WAV
3     (C{1-6}_T{00-19}.wav)
4     Distancias.txt                  # Longitudes vibrantes
5     por traste
6     Datos_de_Tension.csv            # Datos crudos del ensayo
7     de deflexi n
8     Datos de Tension.xlsx           # Original Excel del ensayo
9     de tensi n
10
11     analisis_guitarra.py            # Paso 1: FFT ->
12     frecuencias_fundamentales.csv
13     analisis_paso2_fL.py            # Paso 2: f0 vs L
14     (bivariado)
15     analisis_paso3_mu.py            # Paso 3: f0 vs mu
16     (bivariado)
17     analisis_paso4_T.py             # Paso 4: f0 vs T
18     (bivariado)
19     regresion_simbolica.py          # Regresi n simb lica
20     conjunta
21
22     frecuencias_fundamentales.csv    # Salida paso 1
23     datos_fL.csv                    # Salida paso 2
24     datos_fmu.csv                   # Salida paso 3
25     datos_fT.csv                    # Salida paso 4
26     dataset_mersenne.csv            # Dataset combinado
27     para SR
28
29     figuras/                        # Todas las figuras
30     generadas
31     C{1-6}_T{00-19}_espectro.png    # 120 espectros FFT
32     resumen_cuerda{1-6}.png

```

```

22     resumen_global.png
23     overlay_trastes.png
24     fL_cuerda{1-6}.png
25     fL_normalizado.png
26     fL_constante.png
27     fmu_por_traste.png
28     fmu_exponentes.png
29     fmu_normalizado.png
30     fT_ajuste.png
31     fT_normalizado.png
32     sr_paridad_Lmu.png
33     sr_paridad_T.png
34     sr_paridad_conjunto.png
35     sr_exponentes.png
36     sr_gplearn.png
37     sr_comparacion_curvas.png

```

§B. Fragmentos de código clave

B.1. Extracción de f_0 por FFT (analisis_guitarra.py)

Listing 2: Núcleo del análisis espectral.

```

1  import numpy as np
2  from scipy.io import wavfile
3
4  def extraer_f0(ruta: Path, f_min: float, f_max: float) -> float:
5      sr, data = wavfile.read(ruta)
6      if data.ndim > 1:
7          data = data.mean(axis=1)
8      data = data / np.max(np.abs(data))          # normalizar
9      ventana = np.hanning(len(data))
10     espectro = np.abs(np.fft.rfft(data * ventana)) ** 2
11     freqs     = np.fft.rfftfreq(len(data), 1/sr)
12     mask      = (freqs >= f_min) & (freqs <= f_max)
13     i_pico    = np.argmax(espectro[mask])
14     # Refinamiento parabólico sub-bin
15     idx = np.where(mask)[0][i_pico]
16     if 0 < idx < len(espectro) - 1:
17         delta = 0.5 * (espectro[idx-1] - espectro[idx+1]) \
18             / (espectro[idx-1] - 2*espectro[idx] +
19                espectro[idx+1])

```

```

19         return freqs[idx] + delta * (freqs[1] - freqs[0])
20     return freqs[idx]

```

B.2. Ajuste potencial log-log (analisis_paso2_fL.py)

Listing 3: Regresión potencial en escala log-log.

```

1 def ajuste_potencial(L_arr: np.ndarray,
2                       f0_arr: np.ndarray) -> tuple[float, float,
3                                                    float]:
4     log_L = np.log10(L_arr)
5     log_f = np.log10(f0_arr)
6     coeffs = np.polyfit(log_L, log_f, 1) # b, log10(a)
7     b, log_a = coeffs
8     a = 10 ** log_a
9     logf_pred = np.polyval(coeffs, log_L)
10    ss_res = np.sum((log_f - logf_pred) ** 2)
11    ss_tot = np.sum((log_f - log_f.mean()) ** 2)
12    r2 = 1.0 - ss_res / ss_tot
13    return float(a), float(b), float(r2)

```

B.3. Regresión simbólica log-lineal (regresion_simbolica.py)

Listing 4: RS para clase de leyes de potencia.

```

1 from sklearn.linear_model import LinearRegression
2
3 def ajuste_loglineal(X: np.ndarray,
4                     y: np.ndarray) -> tuple[np.ndarray, float,
5                                              float]:
6     """
7     Modelo: log(y) = b1*log(X1) + b2*log(X2) + ... + log(C)
8     Returns (coefs=[b1,b2,...], R , C)
9     """
10    reg = LinearRegression().fit(np.log10(X), np.log10(y))
11    C = 10 ** reg.intercept_
12    R2 = reg.score(np.log10(X), np.log10(y))
13    return reg.coef_.copy(), R2, float(C)

```

B.4. Medición de tensión — DCL (analisis_paso4_T.py)

Listing 5: Cálculo de T a partir de la masa y el ángulo.

```
1 import openpyxl, csv
2
3 def convertir_excel_a_csv(xlsx: Path, csv_out: Path) -> None:
4     wb = openpyxl.load_workbook(xlsx, data_only=True)
5     ws = wb.active
6     rows = []
7     for row in ws.iter_rows(min_row=2, values_only=True):
8         masa_g, angulo_deg, T_N, f0_Hz = row[0], row[2],
9             row[4], row[5]
10         if all(isinstance(v, (int, float)) and v > 0
11             for v in (masa_g, angulo_deg, T_N, f0_Hz)):
12             rows.append({'masa_g': masa_g, 'angulo_deg':
13                 angulo_deg,
14                 'T_N': T_N, 'f0_Hz': f0_Hz})
15     #  $T_N = m \cdot g / (2 \cdot \sin(\theta))$       calculada internamente en
16     Excel
17     with open(csv_out, 'w', newline='') as fh:
18         writer = csv.DictWriter(fh,
19             fieldnames=['masa_g', 'angulo_deg', 'T_N', 'f0_Hz'])
20         writer.writeheader(); writer.writerows(rows)
```